Mudanças de valor da ULP e seus efeitos em $(x^{10} + c) - x^{10}$

Observações dos experimentos do notebook ulp.ipynb — aritmética float64 (IEEE 754)

1. Objetivo

Em aritmética exata, $(x^{10} + c) - x^{10} = c$ para qualquer x. Em ponto flutuante, isso deixa de valer quando x^{10} fica grande: o espaçamento entre números representáveis vizinhos — a **ULP** (*unit in the last place*) — cresce com a magnitude, e a soma $x^{10} + c$ precisa ser arredondada para um ponto da grade. Este relatório reúne o que foi observado ao variar x e o valor somado c: potências negativas de 2, inteiros ímpares de 3 a 21 e as frações 1/3, 1/5, ..., 1/15.

2. Como a ULP muda

Um float64 tem 53 bits de significando. Para um número X no intervalo $[2^e, 2^{e+1})$, a ULP vale $\mathbf{2^{e-52}}$: ela é constante dentro de cada intervalo entre potências de 2 e **dobra** sempre que X cruza a próxima potência de 2. Como $X = x^{10}$, cada dobra da ULP acontece quando x é multiplicado por $2^{0,1} \approx 1,072$, ou seja, as faixas de x ficam cada vez mais largas (Figura 1).

O marco principal é $\mathbf{x^{10} = 2^{53}}$ ($x \approx 39,4$): a partir daí a ULP passa de 1, e nem os inteiros consecutivos são mais todos representáveis. Esse é o fenômeno da primeira parte do notebook, com x = 40 ($40^{10} \approx 1,05 \cdot 10^{16}$, ULP = 2).

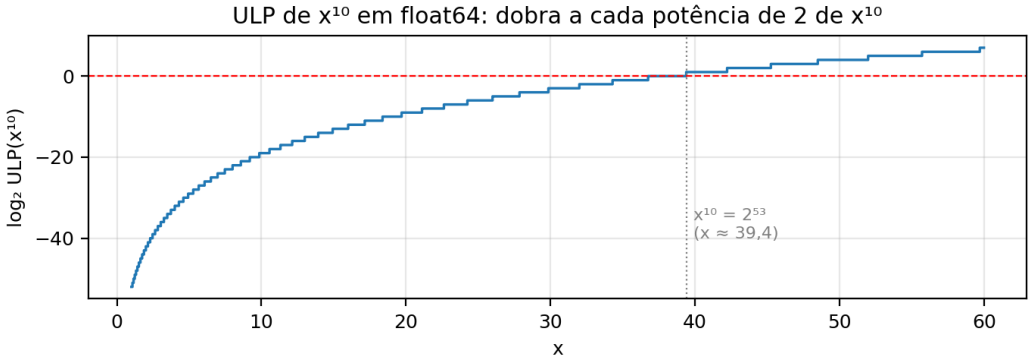


Figura 1 — $\log_2$ da ULP de x^{10}. Cada degrau é um intervalo $[2^e, 2^{e+1})$ de x^{10}; a linha vermelha marca ULP = 1.

A Tabela 1 lista as faixas de x usadas nas análises seguintes.

Faixa de x	ULP de x^{10}	Faixa de x	ULP de x^{10}
24,25 – 25,99	2^{-6}	39,4 – 42,22	2
25,99 – 27,86	2^{-5}	42,22 – 45,25	2^2
27,86 – 29,86	2^{-4}	45,25 – 48,5	2^3
29,86 – 32	2^{-3}	48,5 – 51,98	2^4
32 – 34,3	2^{-2}	51,98 – 55,72	2^5
34,3 – 36,76	2^{-1}	55,72 – 59,71	2^6
36,76 – 39,4	1	59,71 – 60	2^7

Tabela 1 — Faixas de x em que a ULP de x^{10} é constante.

3. Regra geral observada

Em todos os experimentos, o resultado se explica por uma única regra: como x^{10} já é um ponto da grade, **$y = (x^{10} + c) - x^{10}$ é c arredondado para o múltiplo da ULP mais próximo** (a subtração final é exata). Daí saem três regimes:

ULP pequena em relação a c: $y \approx c$, com erro de no máximo meia ULP.

c exatamente no meio de dois múltiplos (empate): vale a regra *round half to even* — o resultado vai para o vizinho cujo último bit é 0. Dependendo de x^{10}, isso pode arredondar para baixo ou para cima.

c < ULP/2: c é totalmente **absorvido** e y = 0.

Uma consequência importante: **o pior erro acontece logo antes da absorção**, quando c está entre ULP/2 e ULP e é arredondado *para cima*, para a própria ULP.

4. Potências negativas de 2 ($c = 2^{-k}$)

Com $c = 2^{-k}$ (k de 1 a 20) e x inteiro de 2 a 40, o resultado foi sempre exatamente **0, l ou 2l** — nunca um valor intermediário — porque tanto c quanto a ULP são potências de 2:

l ≥ ULP: c cabe na grade e a conta sai exata (y = l).

l = ULP/2: empate. Na maioria dos casos arredondou para baixo (y = 0); em 2 casos arredondou para cima e o resultado foi **2l**, o dobro do valor somado.

l < ULP/2: absorvido (y = 0).

Resultado	Condição	Casos (de 780)
l preservado	l ≥ ULP	379
l absorvido	l < ULP/2	371
empate → para baixo (0)	l = ULP/2	28
empate → para cima (2l)	l = ULP/2	2

Tabela 2 — Contagem dos resultados para $x \in \{2, \ldots, 40\}$ e $k \in \{1, \ldots, 20\}$.

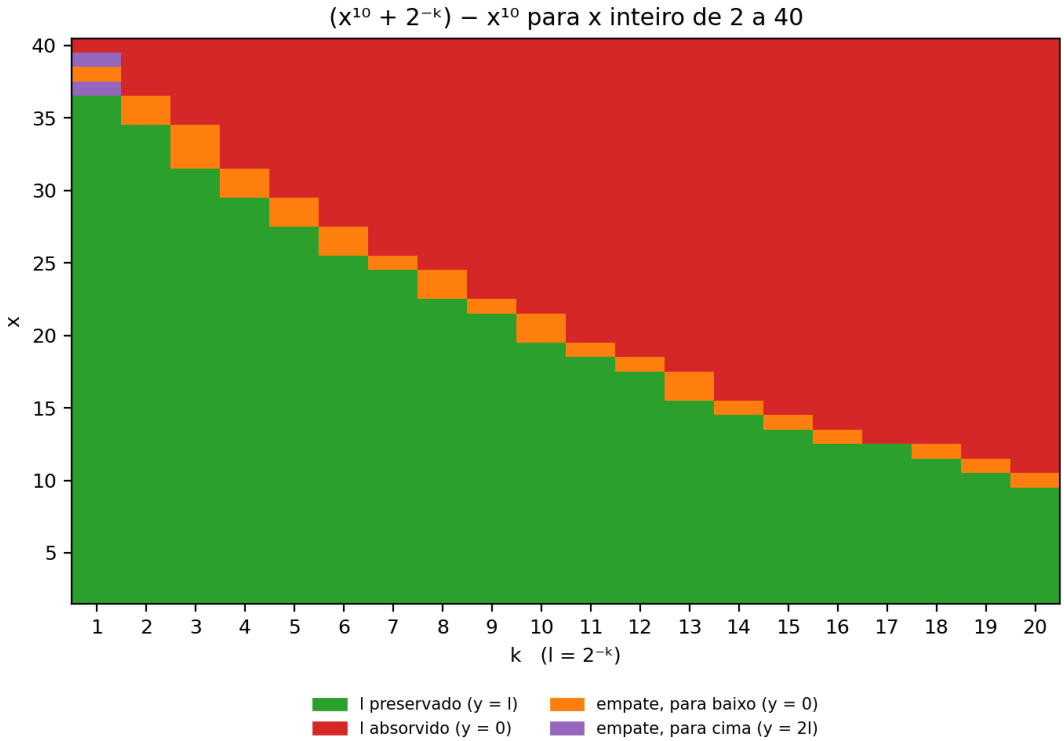


Figura 2 — A fronteira verde/vermelho forma uma escada: quanto maior x, maior a ULP e menor o k a partir do qual l é absorvido. A faixa laranja/roxa é a linha de empates.

Com x contínuo (não só inteiros), cada curva tem um patamar em y = l, uma faixa onde y oscila entre 0 e 2l (empates com paridade variando), e depois cai para zero. Para $l = 2^{-1}$ a faixa de empate fica entre x ≈ 36,8 e 39,4; para $l = 2^{-10}$, entre x ≈ 19,7 e 21,1.

5. Inteiros ímpares (c = 3, 5, …, 21)

Para inteiros, a conta é exata enquanto a ULP for no máximo 1 (x < 39,4). A partir daí, cada dobra da ULP descarta mais um bit de c, e o resultado passa a saltar entre valores acima e abaixo de c antes de zerar (Tabela 3).

ULP	1	2	2^2	2^3	2^4	2^5	2^6	2^7
x	36,8–39,4	39,4–42,2	42,2–45,3	45,3–48,5	48,5–52	52–55,7	55,7–59,7	59,7–60
3	3	2/4	4	0	0	0	0	0
5	5	4/6	4	8	0	0	0	0
7	7	6/8	8	8	0	0	0	0
9	9	8/10	8	8	16	0	0	0
11	11	10/12	12	8	16	0	0	0
13	13	12/14	12	16	16	0	0	0
15	15	14/16	16	16	16	0	0	0
17	17	16/18	16	16	16	32	0	0
19	19	18/20	20	16	16	32	0	0
21	21	20/22	20	24	16	32	0	0

*Tabela 3 — Valor de $(x^{10} + c) - x^{10}$ em cada faixa de ULP. "a/b" indica empate (o resultado depende da paridade de x^{10}); células em vermelho são resultados **maiores** que c.*

ULP = 2: todo ímpar fica exatamente no meio de dois pares, então *todos* dão empate (c − 1 ou c + 1).

ULP ≥ 4: não há mais empates para ímpares; c é arredondado para o múltiplo mais próximo e a curva sobe e desce — c = 21 passa por 20 → 24 → 16 → 32 → 0.

Absorção em degraus: c = 3 some com ULP 8; c = 5 a 15 somem com ULP 32; c = 17 a 21 com ULP 64 — sempre quando c < ULP/2.

Pior erro: c = 17 vira 32 (+88%), logo antes de ser absorvido.

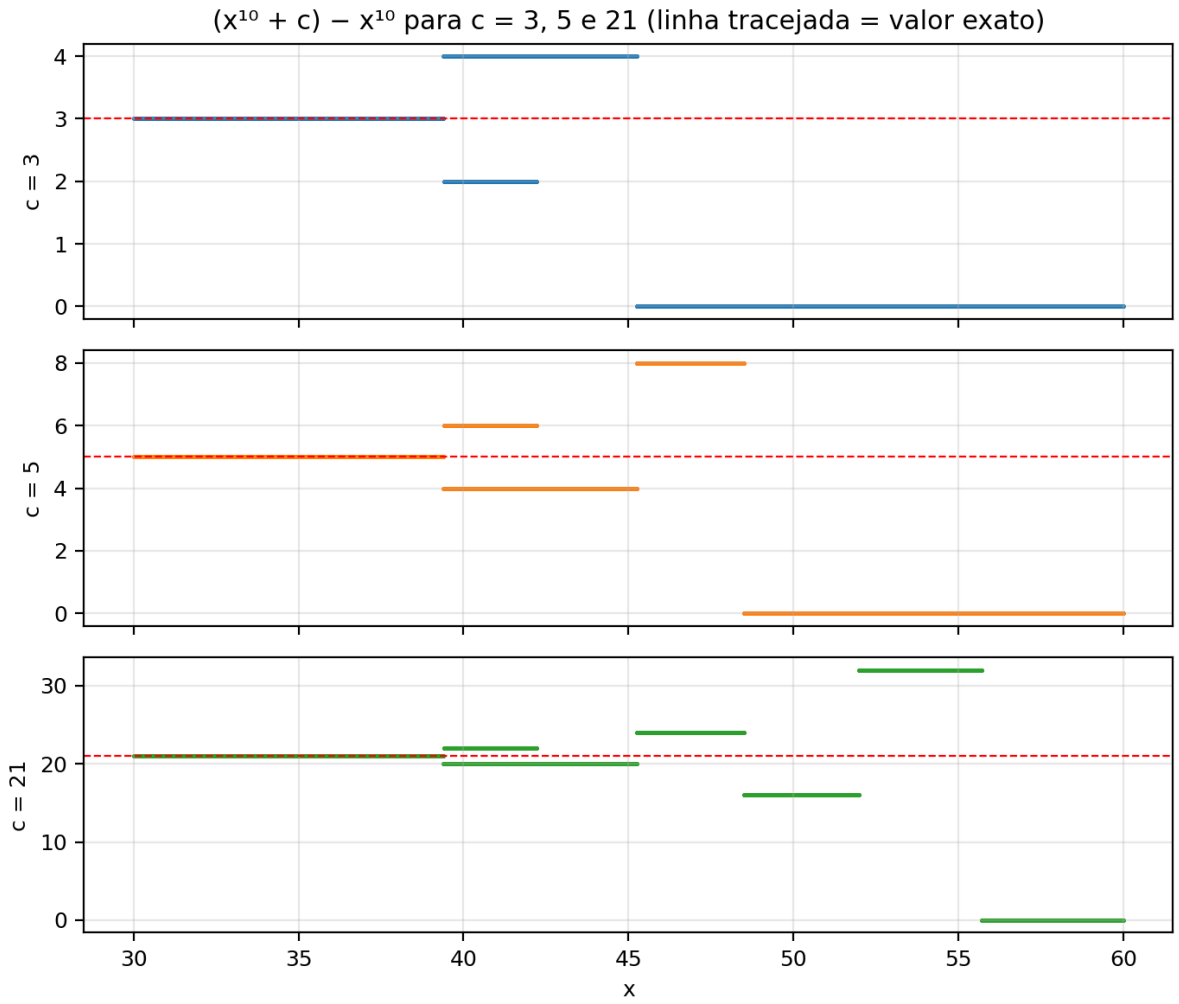


Figura 3 — Curvas para c = 3, 5 e 21. Na faixa de ULP = 2 (empates) os pontos se dividem entre dois valores, conforme a paridade de x^{10}.

6. Frações 1/3, 1/5, …, 1/15

Frações com denominador ímpar não têm representação binária finita, então **o resultado nunca é exato**, nem com x pequeno. O erro absoluto é sempre uma fração fixa da ULP, determinada pelos bits de 1/d que são cortados; por isso o erro relativo cresce em escada, acompanhando a ULP (Figura 4).

Periodicidade: o padrão de arredondamento (acima/abaixo de 1/d) se repete com o período da expansão binária. $1/3 = 0,(01)_2$ alterna a cada faixa e tem erro relativo igual à própria ULP; $1/5 = 0,(0011)_2$ repete o valor em pares de faixas; $1/7 = 0,(001)_2$ fica uma faixa acima e duas abaixo, com erro de 3/7, 2/7 e 1/7 da ULP.

Absorção: quanto menor a fração, mais cedo ela some (quando 1/d < ULP/2).

Pior erro: logo antes de sumir, 1/d é arredondado para cima até a potência de 2 seguinte, 2^{-k}; o erro é $2^{-k} \cdot d - 1$. Ele é máximo quando d está logo abaixo de uma potência de 2 (3, 7, 15) e mínimo logo acima (5, 9).

Fração	Binário (período)	Some a partir de x ≈	Último valor ≠ 0	Pior erro
1/3	$0,(01)_2$	36,8	0,5	50%
1/5	$0,(0011)_2$	34,3	0,25	25%
1/7	$0,(001)_2$	34,3	0,25	75%
1/9	$0,(000111)_2$	32	0,125	12,5%
1/11	$0,(0001011101)_2$	32	0,125	37,5%
1/13	$0,(000100111011)_2$	32	0,125	62,5%
1/15	$0,(0001)_2$	32	0,125	87,5%

Tabela 4 — Comportamento de $(x^{10} + 1/d) - x^{10}$ para x de 1 a 40.

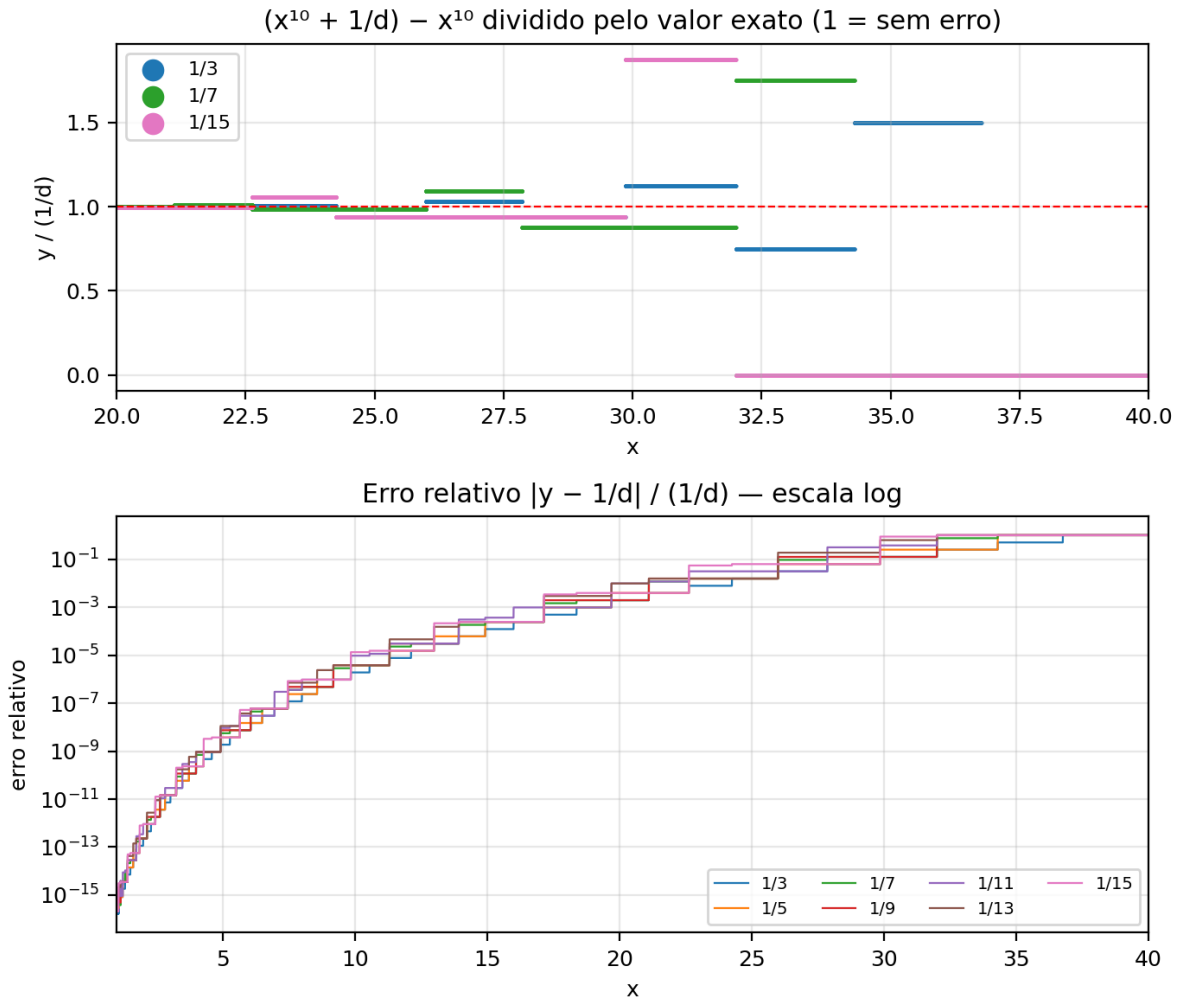


Figura 4 — Em cima, o resultado dividido por 1/d (1 = exato) para 1/3, 1/7 e 1/15. Embaixo, o erro relativo de todas as frações: cresce em degraus junto com a ULP e salta para 1 (100%) quando a fração é absorvida.

7. Conclusões

1. A ULP de x^{10} dobra a cada potência de 2 de x^{10}; acima de x ≈ 39,4 ela passa de 1 e até a soma de inteiros pequenos deixa de ser exata.

2. $(x^{10} + c) - x^{10}$ é sempre c arredondado para um múltiplo da ULP. O erro absoluto é no máximo meia ULP, mas o erro *relativo* cresce até 100% à medida que a ULP se aproxima de c.

3. O resultado não converge suavemente para zero: ele oscila acima e abaixo de c, seguindo os bits de c que vão sendo descartados, e pode chegar a quase o dobro de c (2l para potências de 2, 32 para c = 17, 0,125 para 1/15) logo antes de ser absorvido.

4. Empates (c = ULP/2, ou ímpares com ULP = 2) tornam o resultado dependente da paridade de x^{10} — dois valores de x muito próximos podem dar resultados diferentes.

5. Na prática: subtrair dois números grandes e quase iguais (*cancelamento catastrófico*) não recupera a informação perdida na soma. Para preservar c, é preciso reorganizar a conta ou manter x^{10} numa escala em que ULP $\ll$ c.